

# 发票 OCR

## 思路

- 解析图像 转换为 灰度图
- 二值化处理
- 截取到需要的数据
- 使用矩阵存储图片
- 人为预先设好一些数据
- 矩阵之间进行比较
- 预测
- 输出

## 目标

图片大小 1218\*788

待识别的区域是固定的，我们只识别右上角部分的数字。

使用 `opencv` 进行图片的找轮廓等处理，`pillow` 进行图片的处理。

配合其他的一些库进行更方便的处理，安装请参考下面的教程。

## 开始实践

从我们上面的已知部分来看，我们的计划似乎是完美的，实际上手操作后，则处处都有困难... 不管如何，先做起来再说！

## 环境搭建

如果大家有虚拟环境可以使用虚拟环境：

```
1 python -m virtualenv myenv
2
3 source myenv/bin/activate
4
5 pip install -r requirements.txt
```

也可以直接使用 pip 安装

```
1 pip install -r requirements.txt
```

这样在使用一些第三方库的时候就不会出现找不到的问题了。

## 数据集准备

在完成机器学习的项目中，这部分实际上是相对而言最花时间的地方。我们要做的项目的数据集有时候不是那么丰富。比如我们的这个项目，发票这个东西是涉及到个人隐私的，一般是没有那么多的数据集提供给我们使用的，在这里我为大家提供了我在电商平台上买的一些东西的真实电子发票。



机器编号: 661533632631

## 上海增值税电子普通发票



发票代码: 031001800411

发票号码: 93484577

开票日期: 2019年09月05日

校验码: 46680 10168 34322 98457

购 买 方	名称: 个人 纳税人识别号: 地址、电话: 开户行及账号:	密 码 区	48+6<4>979/96*840<+42+/05+2 658-766+>7814>+<950346>-9/+ 2-+8-81*603497*47*026>+4688 17<+177-766+>7814>+<9505/--					
货物或应税劳务、服务名称 *其他电子设备*华为智选 欧普读写 台灯 学生写字作业阅读 AA级立体 双光源护眼灯 减蓝光 自营台		规格型号	单位	数量	单价	金额	税率	税额
		读写台灯	台	1	149.56	149.56	13%	19.44
合 计						¥149.56		¥19.44
价税合计(大写)		⊗ 壹佰陆拾玖圆整					(小写) ¥169.00	
销 售 方	名称: 上海圆迈贸易有限公司 纳税人识别号: 91310114666025597Y 地址、电话: 上海市嘉定工业区叶城路1118号19层1901室 021-39915587 开户行及账号: 招商银行股份有限公司北京青年路支行 121907731210104	备 注	订单号: 102168400789					

收款人: 王陆      复核: 李思      开票人: 王梅      销售方:(章)      发票专用章

我们这次的目标就是发票的右上角部分, 我们这次的目标是能够识别出来数字即可。

目标已经选好, 我们就可以开始进行预处理了。

## 预处理

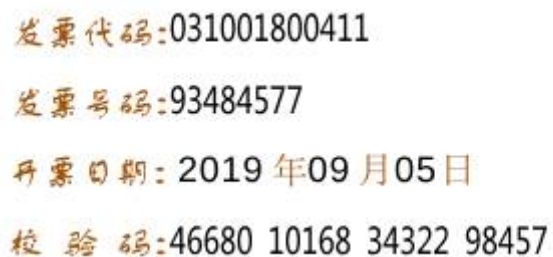
首先我们只要一部分的数据, 那我们要截取那部分的图片即可, 不能截的过大, 否则可能会影响到我们的识别, 也不能过小, 这样我们在对每个数字进行分割的时候反而不方便。

```
1 im = Image.open("./data/test2.png")
2 # 发票代码
3 code = im.crop((850, 15, 1180, 155))
4
5 code.save("cut.png")
```

这里的我们传进去一个 `Tuple` ，指定我们截取的矩形的两个对角的坐标。

之后我们将其保存到本地。

运行上述代码之后我们就可以看到截好的图片了：



发票代码:031001800411  
发票号码:93484577  
开票日期:2019年09月05日  
校验码:46680 10168 34322 98457

接下来我们就进一步的细化我们的处理：进行二值化。

所谓二值化，即将一张图片转换成黑白的样子，这个 `黑白` 和我们平时拍照用的那个滤镜的黑白有点不同，他的黑是**真的黑** `RGB(255,255,255)` 白则是**真的白** `RGB(0,0,0)` ，真正的非黑即白。

但在这之前我们先要将他转换成灰度图，也就是我们平时能经常看到的“黑白滤镜”那个效果。

```
1 img = cv2.imread("cut.png")
2 gray = cv2.cvtColor(img, cv2.COLOR_BGR2GRAY)
3 cv2.imwrite("gray.jpg", gray)
```

这样我们就获得了一个灰度化后的图像：

发票代码:031001800411  
发票号码:93484577  
开票日期:2019年09月05日  
校验码:46680 10168 34322 98457

之后我们对其进行二值化

```
1 # 阈值分割
2 ret, thresh = cv2.threshold(gray, 95, 255, 1)
3
4 cv2.imwrite("thresh.jpg", thresh)
```

`threshold()` 函数的参数

[ ]: <https://blog.csdn.net/u012566751/article/details/77046445> "OpenCV基础—threshold函数的使用"

如下：

- `img` - 待处理的图片
- `thresh` - 阈值
- `maxval` - 最大值
- `type` - 阈值类型

我们倒着——讲述：

阈值类型

我们选择的是 `1`，即大于阈值的变为 白，小于阈值的变为 最大值  
即我们这里设置的黑

## 最大值

为一个灰度值，与阈值类型结合使用。

## 阈值

这个是整个函数最关键的一个点。这个数值的大与小将直接决定我们后面的效果。

我这里的 95 是使用 Photoshop 对几个点测量灰度值和几次尝试之后设置的一个值，大家可以尝试下不同的值的效果：

```
031001900411
76182416
2020  05  17
64111 00147 32117 88712
```

```
还原代码:031001900411
还原代码:76182416
还原日期:2020 . 05  17
还原路径:64111 00147 32117 88712
```

```
还原代码:031001900411
还原代码:76182416
还原日期:2020 年 05 月 17 日
还原路径:64111 00147 32117 88712
```

从上往下值依次是 60, 95, 120

我们可以看到，值比较小的时候我们数字会出现不连贯，不完整的现象，在比较大的时候会显得有一点粗，但是会有其他的一些杂项引入进来，比如说第三行年月日部分三个中文汉字已经有点隐隐约约的显现出来了。

我们不妨就采用 95，让其他的文字稍微的显示出一点点，毕竟天下没有免费的午餐嘛。

## 寻找数字

我们对图像预处理好了，下一步则是对其中的数字进行提取。

我们这里使用 `opencv` 提供的寻找轮廓的功能。这部分内容实质上是图论的一些内容，我们不必刻意追求理解。

```
1 | contours, hier = cv2.findContours(thresh,  
   | cv2.RETR_EXTERNAL, cv2.CHAIN_APPROX_SIMPLE)
```

这里我们传入二值化的数据，同时选择只识别最外面的一层轮廓，不然有些数字如 0，里面可能还会有一圈。后面我们则选择 仅保留轮廓上的拐点信息，即关键点。

我们不妨输出一下找好轮廓的图片：

```
1 for i in range(0, len(contours)):
2     x, y, w, h = cv2.boundingRect(contours[i])
3     print((x, y), (x + w, y + h))
4     # 画出框框
5     cv2.rectangle(img, (x, y), (x + w, y + h),
6                   (255, 0, 255), 1)
7 cv2.imwrite("save.jpg", img)
```

发票代码:0310018004111  
发票号码:93484577  
开票日期:2019年09月05日  
校验码:46680 10168 34322 98457

看起来还不错，接下来就是把他们给分别的截下来。

但是我们注意到，有一些文字的部分内容也被圈起来了，坐标的如发票代码这样的标题我们能很好的处理，但是右边 年月日 部分则要麻烦一点。

我们不妨直接一刀切：直接根据像素的多少决定要不要：



```

1 for i in range(0, len(contours)):
2     x, y, w, h = cv2.boundingRect(contours[i])
3     # print((x, y), (x + w, y + h))
4     # cv2.rectangle(img, (x, y), (x + w, y + h),
    (255, 0, 255), 1)
5
6     # 75 是个神秘的数字
7     if h*w >= 75:
8         newimage = thresh[y : y + h , x : x + w
9     ]
10        cv2.imwrite("./result/" + str(i) +
    ".jpg", newimage)

```

这里我们规定了 75 作为分解的值，因为预设数据集是我使用第一张测试图片截取的结果，经过统计之后我认为这个值作为阈值是比较合适的。

现在，我们打开 result 文件夹就能看到一堆数字的图片了。

## 预设数据

这里我提供给大家已经截好的二值化后的 0-9 的数字，他们的大小大概都在 12x7 左右。

因为我们要比较两个图片的相似程度，我们不妨先把这里图片转换成矩阵的形式，方便后面进行使用：

```

1 preset_path = "./preset"
2
3 store = {}
4

```

```
5 def get_preset():
6     for root, dirs, files in
os.walk(preset_path):
7         for f in files:
8             file_full_path = os.path.join(root,
f)
9             # 用PIL中的Image.open打开图像
10            image = Image.open(file_full_path)
11            # 转化成numpy数组
12            arr = np.array(image)
13
14
15            file_ext = f.rsplit('.', maxsplit=1)
16            file_name = file_ext[0]
17
18            store[file_name] = arr
```

这样我们就得到了一个以数字的值为键，数字图片的矩阵作为值的一个字典。

## 比较

万事俱备，我们就差最后一步了！

这时候我们只要比较两个矩阵之间的相似程度，排序一下，就能知道这个图片更像哪个数字了。

两个矩阵之间的相似程度比较，我们首先想到的一个非常直观的方法：[余弦相似度法](#)

然而这里我们不能使用，因为我们截下来的数字图片的大小是不固定的，若你了解过矩阵的乘法就知道，两个矩阵能否相乘是有一定条件的。

这里我们只能退而求其次，计算一下这张图片的“哈希值”<sup>[1]</sup>

这里我们采用感知哈希法：

```
1 avg = arr.mean()
2
3 hash_val = ''
4
5
6 for x in range(arr.shape[0]):
7     for y in range(arr.shape[1]):
8         if arr[x,y] > avg:
9             hash_val += '1'
10        else:
11            hash_val += '0'
```

然后我们只要比较两个字符串的差异即可。这时候还是回到那个问题上，我们的两个字符串长度是不固定的，如何才能比较差异呢？

我这里使用了 [莱文斯坦距离](#) 来进行计算。简单来说是将字符串 a 变成字符串 b 所需要进行变化的最少次数。

好，问题终于解决了！

## 开始识别

那我们回到截取数字的部分，对其进行小修改即可：

```
1 for i in range(0, len(contours)):
2     x, y, w, h = cv2.boundingRect(contours[i])
3     # print((x, y), (x + w, y + h))
4     # cv2.rectangle(img, (x, y), (x + w, y + h),
5     (255, 0, 255), 1)
6
7     if h*w >= 75:
8         # ！ 注意这里截取的是二值化后的图片
9         newimage = thresh[y : y + h , x : x + w
10 ]
11         new_image_array = np.array(newimage)
12
13         # 比较
14
15         init = -1
16         index = -1
17
18         # store 即 预设数据的字典
19         for k, v in store.items():
20             rsp = leven(new_image_array, v)
21             if rsp >= init:
22                 index = k
23                 init = rsp
24
25         print("result", index)
```

```


25         cv2.imwrite("./result/" + str(i) + "-" +
        str(index) + ".jpg", img[y : y + h , x : x + w
    ])

```

这里的 `leven` 是我进行简单的包装之后的一个方法，因为传入进去的一个是 图片的矩阵，一个则是字符串，我们对其简单处理下返回比较之后的值。

后面我们则输出识别的结果，这里我们直接保存到图片的名称中，图片的名称格式为 `顺序号-识别结果.jpg`

我们使用 `test2.png` 作为输入样例，运行程序，查看输出结果：



经过统计之后我们得到的结果：

数字	正确数	总数	准确率/%
0	28	36	77.7
1	35	39	89.7
2	8	17	47.1
3	3	5	60.0
4	14	14	100.0
5	0	1	0.0
6	8	8	100.0
7	16	16	100.0
8	6	10	60.0
9	4	4	100.0
错误图片		3	

## 分析与反思

可以看到，0，1的数量比较的多，我们在这两个数字上的准确率还行。

个别数字的样本太少，不能一定程度的反映问题，但是还是能看到识别率比较低的。

在统计上述的表格数据时，我还注意到数字 8 容易被识别为 3，这是因为 3 很像是 8 的一半，而我们的特征算法不能很好的分辨这两种数字的特点。

后续我们要进行更多的输入，进行统计，来看一下我们哪个数字的准确率低。更要关注错误识别的数字更容易被识别为哪些数字。

同时注意到我们还有三个不应该输入进来的，也就是截取到了非数字的部分，这是不应该的，则应该对截取部分的代码进行改善。

## 后续的提升

### 预处理

二值化的时候我们不妨考虑对不同的数字或者部分进行不同的阈值。即便我们使用的电子版，放到足够大时我们会发现同一个数字的“颜色深浅”是有细微差别的，这点在我们进行二值化的时候会被放大到这个数字会有“笔画分离”的效果，这对于我们后面进行寻找轮廓的时候是致命的。

我们预设数据集由于每次进行检测的时候是不需要再进行处理，我们就不妨对预设的数据集进行一次处理，持久保存到文件的形式。

每次检测的时候读取文件中的数据进行处理，剩下一些计算量。

### 数据集

最简单的方法，扩大数据集的量，对于预设数据(preset)中的数据应该不止有单一的一张，一个数字的预设图片应该多放几张

显然这会直接的提升每次进行预测时候的工作量，这时候应该考虑下对算法的优化了。

## 算法上的提升

我们的算法比较的简单，但足以能完成这个问题。

使用机器学习去解决实际问题时，我们不应事先考虑太多的细枝末节的因素，不妨先做出来一个勉强能用的，后面再慢慢改进。（数学之美）

对于上述预设的数据集问题，也许我们可以考虑对于一个数字的不同图片之间取不同的部分做单独的处理，将相同的部分只存一份，这样会降低一些计算量。

对于测试数据和预设数据之间进行比较的部分，我们可以考虑更优秀的算法，这部分是 AI 的核心。

计算两图的相似性（以图搜图）

## 从数字到文字

然而我们的这个识别距离“能用”其实还是有不小的差距，因为我们连文字都无法识别出来，只能识别固定的格式的数字。

试想倘若这张发票中的数字的字体换了另外的一个字体，这套方法的识别效率可能就会低不少。

但若换成了文字，我们在“获取轮廓”部分就要多吃一些处理。

我们要对临近的“偏旁”或者“文字的小部分”结合起来成为一个整体的文字，汉字是十分复杂的，倘若碰上了 biang 这种字，我们的算法会遇到不小的难题。

## 鲁棒性 Robustness

即 **健壮性**。能识别不同的字体，能应对复杂的汉字，这些都是我们模型的健壮性的体现。我们后续要积极的提升我们模型的鲁棒性。



- 
1. Zhihu - 计算两图的相似度 (以图搜图) <https://zhuanlan.zhihu.com/p/93893211> ↗